

Détection d'apnée du sommeil par audio smartphone

Ce rapport a été rédigé avec l'aide d'une IA générative, à partir du travail expérimental et des analyses que j'ai menés moi-même.

Contexte scientifique

L'apnée du sommeil touche environ un milliard de personnes dans le monde, mais la plupart ne sont jamais diagnostiquées. Le diagnostic actuel repose sur la polysomnographie, une nuit à l'hôpital avec de nombreux capteurs (électrodes, capteurs respiratoires, oxymètre). C'est coûteux, contraignant, et donc rarement effectué en prévention.

Depuis quelques années, plusieurs équipes de recherche explorent une alternative prometteuse : détecter l'apnée à partir d'enregistrements audio réalisés au smartphone, posé sur la table de nuit. L'objectif est de rendre le dépistage accessible à grande échelle.

Trois travaux récents fixent l'état de l'art. Han et al. (2026) utilisent un modèle Transformer sur des données d'hôpital de 287 patients et atteignent 88 % de bonnes prédictions grâce à des fenêtres audio de 40 secondes autour de chaque événement. Ils montrent aussi qu'un modèle entraîné en conditions cliniques perd 25 points quand il est testé sur du son ambiant réel. Le et al. (2023) combinent plusieurs types de réseaux de neurones et entraînent le modèle à ignorer les bruits parasites (télévision, ventilateur, voix), obtenant 88,8 % sur un dataset privé de 1315 nuits. Wang et al. (2022) proposent une approche plus simple avec un réseau de neurones convolutif classique sur 59 patients, à 89 % — un score encourageant mais qui reste à confirmer à plus grande échelle.

Ces résultats sont impressionnants, mais reposent tous sur des datasets d'hôpital de grande taille et des micros professionnels.

Question de recherche

J'ai voulu comprendre concrètement pourquoi, malgré ces publications, aucune application grand public à ce jour ne dépasse 75 % de fiabilité en conditions réelles.

Mon hypothèse de départ était le glissement de distribution entre données d'entraînement (hôpital, micro pro) et données de production (chambre à coucher, smartphone). Un modèle entraîné sur des enregistrements cliniques ne fonctionnerait pas dans la vraie vie.

Pour tester cette hypothèse, j'ai construit un pipeline complet sur un dataset publié en 2025 par Tao et al. dans Nature Scientific Data. C'est le seul jeu de données publiquement disponible où l'audio a été directement enregistré par un vrai smartphone posé sur la table de nuit, avec annotations médicales validées par polysomnographie simultanée.

Approche

Le dataset comprend 48 patients et environ sept heures d'audio par patient, avec des annotations d'experts. Le traitement consiste à découper l'audio en segments de 40 secondes autour de chaque événement, puis à convertir chaque segment en mel-spectrogramme (une représentation visuelle du son adaptée à l'oreille humaine).

Cinq approches de deep learning ont été comparées, du CNN classique aux modèles qu'on force à ignorer l'identité du patient. La validation repose sur un découpage strict par patient : aucun patient n'apparaît à la fois dans l'entraînement et dans le test, ce qui permet de mesurer la vraie capacité de généralisation à des personnes inconnues.

Démarche et diagnostic

Cinq approches ont été testées sur le même dataset, avec exactement le même découpage par patient à chaque fois. Cela permet une comparaison rigoureuse entre les méthodes.

Approche	Idée	Accuracy	AUC
CNN classique sur mel-spectrogramme	Motifs visuels dans l'image du son	65 %	0,67
Transfer learning avec YAMNet	Modèle Google pré-entraîné sur 2M de sons	67 %	0,73
YAMNet forcé à ignorer l'identité	Le modèle est puni s'il devine le patient	67 %	0,72
CNN + BiLSTM	Lecture temporelle du mel-spectrogramme	66 %	0,73

Tous les modèles plafonnent au même niveau, autour de 65 à 67 % d'accuracy et 0,72 à 0,73 d'AUC. Ce n'est pas un hasard, et c'est là que le projet devient scientifiquement intéressant.

Choix méthodologiques

Les fenêtres audio font 40 secondes, avec un décalage de +5 secondes après la fin de chaque événement. Ce choix vient de Han et al. (2026), qui ont montré qu'aller plus court ou plus long dégrade les performances : 40 secondes captent la respiration avant l'apnée, l'apnée elle-même, et la reprise brusque après.

Le découpage est strict par patient : 32 patients pour l'entraînement, 8 pour la validation, 8 pour le test. Un patient n'apparaît jamais dans deux ensembles à la fois. Ce point est crucial : sans lui, on obtient des scores artificiellement élevés (jusqu'à 90 % et plus) qui s'effondrent en conditions réelles.

L'équilibrage est fait patient par patient, moitié segments d'apnée moitié segments normaux. Sans cela, un modèle peut atteindre 85 % d'accuracy simplement en prédisant toujours la classe majoritaire.

Le vrai résultat : comprendre le plafond

Face à ce plafond, je me suis posé une question inhabituelle : et si le modèle n'apprenait pas vraiment à détecter l'apnée, mais autre chose ?

Pour le tester, j'ai fait une expérience simple mais très parlante. J'ai pris les représentations audio produites par YAMNet, et au lieu de demander au modèle de prédire "apnée ou pas apnée", je lui ai demandé de prédire quel patient a produit ce son.

Résultat : 97,4 % de bonnes réponses sur 48 patients possibles (le hasard donnerait 2 %). Autrement dit, YAMNet n'extrait pas d'abord la pathologie, il extrait l'identité de la personne, c'est-à-dire sa voix, l'acoustique de sa chambre et la position de son téléphone. Le signal individuel est beaucoup plus fort que le signal médical.

Ce constat explique pourquoi tous les modèles plafonnent au même endroit. Peu importe l'architecture, si les données d'entrée codent d'abord "qui parle" plutôt que "que se passe-t-il", le modèle apprendra en priorité à reconnaître les patients d'entraînement, et échouera face à des patients nouveaux.

Ce que ce résultat change

Ce constat remet en cause une pratique courante dans le domaine : utiliser un modèle audio pré-entraîné (YAMNet, HuBERT, wav2vec) n'est pas toujours une bonne idée en santé, car ces modèles ont été conçus pour distinguer les personnes, pas les pathologies.

Cela pointe une piste de recherche que je n'ai pas eu le temps d'explorer : construire un modèle audio qui apprend à ne pas se laisser distraire par l'identité du patient.

Questions de recherche ouvertes

Ce projet a produit un résultat scientifiquement clair : le vrai obstacle n'est pas l'architecture, c'est la façon dont l'audio est représenté. Cela ouvre plusieurs pistes concrètes.

Représentations audio invariantes au patient

L'expérience de signature patient à 97 % suggère qu'il faudrait construire des représentations audio qui capturent la pathologie sans capturer la personne. Ma tentative avec un modèle domain-adversarial a fait chuter l'identification patient de 53 % à 12 %, mais ne s'est pas traduite par un gain de performance équivalent. Cet écart est en soi une question intéressante à creuser : jusqu'où peut-on supprimer la signature individuelle sans détruire aussi le signal utile ?

Une piste complémentaire serait l'apprentissage auto-supervisé sur des données de sommeil non annotées, qui existent en grande quantité contrairement aux données annotées. L'idée serait d'apprendre des représentations générales sans jamais utiliser l'étiquette d'identité ni celle de pathologie.

Combinaison entre datasets de contextes acoustiques différents

Le dataset Tao (48 patients smartphone) est unique mais limité. PSG-Audio (287 patients en hôpital) est plus grand mais dans un autre contexte acoustique, avec un micro professionnel placé à un mètre du patient.

Combiner intelligemment ces deux sources, sans juste les mélanger (ce qui créerait un biais), est un vrai problème de recherche. Comment tirer parti de la quantité du dataset hôpital tout en restant fidèle à la distribution smartphone ? C'est un cas d'école de transfert entre domaines acoustiques différents.

Prise en compte de la structure temporelle longue

Un aspect que je n'ai pas eu le temps d'approfondir : au lieu de traiter chaque segment de 40 secondes indépendamment, exploiter la séquence complète de la nuit.

Une apnée isolée est difficile à détecter, mais une série d'apnées qui se répètent toutes les 30 secondes est un signal beaucoup plus fort. Modéliser cette dynamique à long terme, à l'échelle de plusieurs minutes ou de la nuit entière, est un défi ouvert, et probablement une clé pour dépasser les plafonds actuels des modèles qui regardent chaque événement isolément.

Comprendre ce qu'apprend vraiment le modèle

Un dernier axe qui me passionne : au-delà de mesurer une accuracy, chercher à visualiser ce que le modèle regarde dans le mel-spectrogramme quand il prédit une apnée. Cela permettrait de vérifier qu'il apprend bien des motifs physiologiquement plausibles (silence puis reprise brusque) plutôt que des artefacts (bruit de fond stable, position du micro).

C'est aussi un enjeu important pour envisager un jour un usage médical réel : un modèle boîte noire ne sera jamais adopté par les médecins.